

Universidad de
SanAndrés

MAESTRÍA EN ECONOMÍA

BIG DATA

Trabajo Práctico 1

Análisis Descriptivo y Predicción de Informalidad

Mateo Arechavala
Tomás E. Baigorria
Martín A. Fradkin

Profesor: Walter Sosa Escudero
Tutora: Luciana Ramirez

5 de noviembre de 2026

El objetivo de este trabajo es predecir si un ocupado es informal. Entendemos la registración del trabajador como una variable binaria (se es formal o se es informal), por lo que lo que estimamos es la probabilidad $p = P(Y = 1 \mid X)$ de que un ocupado sea informal, y a partir de ella lo clasificamos. Utilizamos datos de la Encuesta Permanente de Hogares (EPH) del primer trimestre de 2026, descargados de la página oficial del Instituto Nacional de Estadística y Censos (INDEC).

El trabajo en su totalidad consta de la limpieza y consolidación de la base (Parte I), tres distintas estimaciones de p (Partes II y III) y una lectura final (Parte IV), donde interpretamos el desempeño general de los tres modelos estimados y dirimimos cuál adoptamos como resultado final.

Los modelos en cuestión son Logit, Análisis Discriminante Lineal (LDA) y Vecinos Cercanos (KNN).

Parte I: Analizando la base

Descargamos las bases a nivel individual y de hogares de la EPH para el primer trimestre de 2026 de la página oficial del INDEC[1]. La base individual tiene 43.739 personas y 234 variables; la de hogares, 15.447 hogares y 98 variables. El diccionario de variables es el *Diseño de registros y estructura para las bases preliminares Hogar y Personas* (INDEC, agosto de 2026). Nuestra unidad de análisis es el individuo (la persona ocupada), y la base de hogares aporta las características del hogar que consideramos predictoras de la variable dependiente de interés. La primera parte se compone de cuatro incisos y se organiza de la siguiente manera: (1) selección de variables predictoras y limpieza; (2) construcción de nuevas variables; (3) valores faltantes y descripción de la matriz de predictoras; (4) partición de la base en una de prueba y otra de entrenamiento.

Inciso 1

Aplicamos un filtro por la condición de actividad del individuo para quedarnos únicamente con la porción de la muestra que se encuentra ocupada (`ESTADO` $= 1$). La cantidad de observaciones pasa de 43.739 a 19.573. Construimos la variable dependiente `informal` a partir de la variable `EMPLEO` (1 = formal; 2 = informal; 9 = Ns/Nr) de la base, que reporta 10.762 trabajadores formales, 8.798 informales y 13 sin respuesta (código 9) que se eliminan, por lo que las observaciones se reducen a $n = 19.560$. Con estos números, los informales representan el 44,98 % de la muestra, de donde surge un piso de referencia: un modelo que clasifique a todos como formales acertaría el 55,02 % de las veces sin mirar ninguna característica, y un modelo útil debiera superar esa cifra. Finalmente, `informal` $= 1$ si `EMPLEO` $= 2$ e `informal` $= 0$ si `EMPLEO` $= 1$, porque los modelos estiman la probabilidad de ser informal, $P(Y = 1 \mid X)$.

Previo a la selección de las variables que constituirán nuestra matriz de predictores X, identificamos aquellas variables que quedan excluidas. En particular, las variables que forman parte de la definición de `EMPLEO` se descartan como predictoras debido a que la variable `informal` es una función de las mismas. Es decir, el INDEC define a un trabajador como formal o informal en base a estas variables[2]. Los asalariados son informales si no tienen descuento jubilatorio (`PP07H`). Por su parte, los independientes se clasifican según el registro de su actividad y sus aportes (`PP05I` a `PP05K`). Por poner un ejemplo, todos los trabajadores asalariados (`CAT_OCUP` $= 3$) que tienen descuento jubilatorio en su trabajo (`PP07H` $= 1$) son formales. Esto es, entre los asalariados, `PP07H` reproduce `informal` sin un solo error. La razón por la cual esas variables con ajuste casi perfecto no se sostendrían fuera de la muestra es que un modelo necesita identificar informales donde no se observa la registración, es decir, donde no conocemos estas variables. Si las conociéramos, automáticamente sabríamos su condición y no sería necesario estimar una predicción. En definitiva, el modelo no aprende qué características se asocian con la informalidad y luego falla al querer predecir con variables no observables.

[1] https://www.indec.gob.ar/indec/web/Institucional-Indec-BasesDeDatos

[2] INDEC (2025), *Diseño conceptual y metodológico para la medición de la informalidad laboral con datos de la EPH*, Metodología INDEC N.º 43.

Adicionalmente, identificamos más variables que se suman a la lista de las excluidas por representar, básicamente, una extensión del problema desarrollado en el párrafo anterior. Se trata de variables que dependen o están altamente correlacionadas con las de la definición de informalidad. Por un lado, están los saltos en el cuestionario, una serie de preguntas que se realizan condicionales a la respuesta obtenida en una pregunta anterior. Por ejemplo, las preguntas `PP07I2`, `PP07I3` y `PP07I4` (si el empleador hace descuentos a otros, si emite facturas, si tiene contador) se hacen sólo a asalariados sin descuento jubilatorio, i.e., informales de acuerdo al criterio del INDEC, por lo que el solo hecho de haberlas respondido revela la condición del trabajador. Por otro lado, se encuentran las variables que no forman parte de la definición, pero que son consecuencias de la formalidad. El caso que resaltamos es el de `CH08` (cobertura médica): registrar a un asalariado implica, en un mismo acto, el aporte jubilatorio y la obra social. Por eso el 80 % de quienes tienen obra social son formales y el 95 % de quienes no pagan cobertura son informales.

Seleccionamos 21 variables socioeconómicas que consideramos relevantes para predecir informalidad y que, junto con las nueve que construimos en el inciso 2, constituyen nuestra matriz de predictores X (Tabla 1). El criterio de selección no contempla la correlación con la variable de interés debido a las razones previamente mencionadas, sumado al hecho de que elegir variables mirando su correlación con Y en la base completa (sin particionar) usa información de la base de prueba y sobreestima el acierto del modelo en el test. Las variables elegidas satisfacen dos condiciones: relevancia (un mecanismo que explique su influencia sobre la variable de interés) y disponibilidad (que se observe sin conocer la registración del trabajador y esté definida para todos los ocupados). La segunda condición excluye a las no observables. De 234 variables, hay 21 que cumplen estos requisitos, y las incluimos a todas en la matriz X.

A continuación describimos los mecanismos pensados. Registrar a un trabajador tiene costos (aportes, indemnización) y no registrarlo tiene riesgos (multas), lo que constituye un *trade-off*. Las variables que desbalancean esa tensión son el tamaño del establecimiento (a menor tamaño, menor riesgo de inspección y mayor costo fijo de registrar), el sector (ej.: el sector estatal está sujeto a normas administrativas y control público), la rama o los contratos temporales (elevan costos y dificultan la inspección), el lugar de trabajo (menos inspección cuando no hay un establecimiento fijo registrado) y la categoría ocupacional (a diferencia de los asalariados, los cuentapropistas deben evaluar los costos y beneficios de registrarse). En la dimensión del trabajador, el ingreso mensual y querer trabajar más horas pueden delatar puestos de mayor rotación y baja productividad (incentivos a no registrar), el ciclo de vida laboral —jóvenes entrando al mercado vía puestos informales— justifica la inclusión de la edad, y ser estudiante es compatible con puestos de horario flexible y tiempo parcial. El pluriempleo, por su parte, indicaría que la actividad principal es precaria y no alcanza, con excepciones para ciertos trabajadores formales calificados (periodistas, docentes). El origen se considera por las barreras de entrada que enfrenta un inmigrante (o en sentido contrario, un migrante interno se muda porque consiguió un buen trabajo). En la dimensión del hogar, el ingreso per cápita familiar aproxima los recursos con los que cuenta (un hogar con menos recursos enfrenta un mayor costo relativo de esperar por un empleo formal). Ser jefe de hogar o estar casado eleva el valor de la cobertura que da el empleo registrado, que alcanza a toda la familia (obra social, aportes jubilatorios), mientras que los menores de 10 años empujan hacia empleos de horario flexible o cercanos a la casa por la carga de cuidado, que recae mayormente sobre las mujeres. El sexo, en cambio, tiene un efecto ambiguo: las mujeres están sobrerrepresentadas tanto en el servicio doméstico, muy informal, como en la enseñanza y la salud públicas, muy formales. La tenencia de la vivienda aproxima el patrimonio y la estabilidad del hogar. Por último, en la dimensión territorial, la región captura diferencias en la estructura productiva y en la capacidad de fiscalización (ej.: el peso del empleo público; grandes empresas extractivas en la Patagonia), y vivir en un aglomerado de 500.000 habitantes o más tiene un efecto a priori ambiguo, porque las grandes ciudades concentran empresas grandes y controles, pero también un sector informal urbano extendido.

Tabla 1: Variables de la matriz X: 21 seleccionadas (inciso 1) y 9 construidas (inciso 2)

Base limpia	Origen (EPH)	Variable	Tipo / recodificación
Seleccionadas			
`region`	REGION	Región de residencia	6 cat. (ref.: GBA)
`mas500`	MAS_500	Aglomerado de 500.000 habitantes o más	Dummy
`jefe`	CH03	Jefe o jefa de hogar	Dummy (jefe/a)
`mujer`	CH04	Sexo: mujer	Dummy
`edad`	CH06	Edad en años cumplidos	Años
`estado_civil`	CH07	Estado civil	5 cat. (ref.: soltero)
`asiste_educ`	CH10	Asiste a un establecimiento educativo	Dummy
`origen`	CH15	Lugar de nacimiento	3 cat. (ref.: misma prov.)
`cat_ocup`	CAT_OCUP	Categoría ocupacional	3 cat. (ref.: asalariado)
`pluriempleo`	PP03C	Tiene más de una ocupación	Dummy
`quiere_mas_horas`	PP03G	Quería trabajar más horas	Dummy
`busca_otro_empleo`	PP03J	Busca otro empleo además del actual	Dummy
`sector`	PP04A	Tipo de empleador: estatal, privado u otro	3 cat. (ref.: privado)
`rama`	PP04B_COD	Rama de actividad del establecimiento	13 ramas + no especificada (ref.: comercio)
`tamano_estab`	PP04C + PP04C99	Personas que trabajan en el establecimiento	3 tramos + Ns/Nr (ref.: >40)
`lugar_trabajo`	PP04G	Lugar principal de trabajo	8 cat. (ref.: local)
`contrato_temporal`	PP07C	Empleo con fecha de finalización	Dummy
`ingreso_ocup`	P21	Ingreso mensual de la ocupación principal	Pesos
`ipcf`	IPCF	Ingreso per cápita familiar	Pesos
`menores10`	IX_MEN10 (hogar)	Miembros del hogar menores de 10 años	Personas
`tenencia`	II7 (hogar)	Régimen de tenencia de la vivienda	4 cat. (ref.: propietario)
Construidas			
`edad2`	CH06	Edad al cuadrado	Años al cuadrado
`educ`	CH12, CH13, CH14	Años de educación aprobados	Años de educación
`horastrab`	PP3E_TOT, PP3F_TOT	Horas semanales en todas las ocupaciones	Horas semanales
`nhogar`	Conteo por hogar	Cantidad de miembros del hogar	Personas
`prop_ocupados`	ESTADO, por hogar	Proporción de ocupados en el hogar	Proporción
`calificacion`	PP04D_COD (CNO)	Calificación del puesto (CNO 2001)	4 cat. (ref.: operativa)
`hacinamiento`	IX_TOT / II1	Personas por ambiente del hogar	Personas por ambiente
`mujer_x_menores10`	CH04 × IX_MEN10	Mujer × menores de 10 en el hogar	Interacción
`sobrecalificacion`	`educ`, `calificacion`	Educación alta en puesto de baja calificación	Dummy (ver inciso 2)

Reemplazamos los valores sin sentido. Primero, revisamos cuáles son los valores que toma cada una de las 21 variables y, contrastando con el Diseño de registro, identificamos el código de no respuesta correspondiente, que no es el mismo para todas (0; 9; 99; 999; -9). Luego, aplicamos el reemplazo variable por variable. La variable `IPCF` (ingreso per cápita familiar) es de montos y utiliza el cero tanto para los hogares sin ingresos como para los que no declaran. Sin embargo, a partir del monto el INDEC asigna a cada hogar un decil de ingreso, cuyo código distingue a los hogares sin ingresos (código 0) de los que no declaran (código 12), lo que nos permite reemplazar únicamente a estos últimos. Dos casos requieren mirar más de una variable. En la edad (`CH06`), un solo ocupado tiene el código 99, que el Diseño de registro reserva para la no respuesta. Lo tratamos como faltante porque su edad no se puede verificar (no tiene fecha de nacimiento registrada) y porque el ocupado que le sigue en edad tiene 88 años. En la rama (`PP04B_COD`), el código 9999 ("Ns/Nr o actividad no especificada claramente", 91 ocupados) pasa a una categoría propia en lugar de agruparse con otras actividades. Por último, en el código de ocupación `PP04D_COD`, reemplazamos los códigos 99996 a 99999 (mal codificado, falta de información, otro y Ns/Nr)[3].

Una vez seleccionadas, las variables se vieron sujetas a decisiones de recodificación, desde combinaciones de variables hasta recategorizaciones (agrupar/eliminar categorías), que tomamos a fin de sortear eventuales problemas de convergencia (logit), colinealidad y no respuesta.

[3]Clasificador Nacional de Ocupaciones, CNO, versión 2001.

Inciso 2

Construimos nueve variables que no están en la base: las cinco que sugiere la consigna y cuatro propias (Tabla 1). El criterio fue que cada variable construida reemplace a sus insumos o los complemente, pero que nunca conviva con una copia de sí misma. La edad al cuadrado complementa a la edad y le permite a la relación con la informalidad tener curvatura. Los años de educación reemplazan a las tres preguntas de las que surgen (`CH12`, `CH13` y `CH14`): sumamos los años previos al nivel más alto cursado y, si no lo terminó, los años aprobados de ese nivel[4]. Las horas trabajadas suman las de todas las ocupaciones; sus 1.469 ceros son ocupados que no trabajaron en la semana de referencia (licencia, vacaciones), no errores. El número de miembros y la proporción de ocupados del hogar se cuentan sobre la base individual completa y no sobre los ocupados, porque así no quedan afuera los niños, los inactivos y los desocupados del hogar. El signo esperado de esta última es ambiguo: más ocupados pueden aliviar la necesidad de aceptar cualquier empleo o, al revés, reflejar que todos salen a trabajar porque el hogar lo necesita.

Las cuatro variables propias buscan complementar a otras que ya están en X sin duplicarlas. La calificación del puesto no existe como variable en la base: la obtenemos del código de ocupación, que combina en cinco dígitos cuatro dimensiones del puesto (497 códigos distintos en la muestra), extrayendo el dígito de la calificación (profesional, técnica, operativa o no calificada). Mide el puesto, mientras que la educación mide a la persona, y ambas difieren cuando alguien trabaja por debajo de su formación. Esa diferencia es la que captura la sobrecalificación, que vale 1 cuando una persona con 15 o más años de educación ocupa un puesto operativo o no calificado. El hacinamiento (personas por ambiente) aproxima la pobreza estructural del hogar y tiene apenas 5 faltantes, contra los 5.661 del ingreso per cápita familiar, con el que correlaciona $-0{,}49$ (aporta información sobre el nivel socioeconómico justamente donde el ingreso no se declara). Por último, la interacción entre ser mujer y la cantidad de menores de 10 años permite que el efecto de los niños sobre la informalidad sea distinto para mujeres y varones.

Inciso 3

La Figura 1 muestra los valores faltantes de la matriz X antes de cualquier tratamiento y antes de pasar las variables categóricas a *dummies* (al hacerlo, un faltante se convierte en ceros y deja de verse). Los faltantes se concentran en cuatro variables: el ingreso per cápita familiar (28,9 %), el ingreso de la ocupación principal (19,0 %), el tamaño del establecimiento (6,5 %) y el contrato temporal (4,9 %). En el resto no superan el 1,5 %. Los dos ingresos están anidados, todo ocupado que no declara su ingreso tampoco tiene ingreso per cápita familiar, que se calcula con los ingresos de todos los miembros del hogar. En total, el 36,1 % de las observaciones tiene al menos un faltante, pero sólo 365 lo tienen fuera de esas cuatro variables.

Para tratar los faltantes seguimos un criterio según el tipo de variable (Tabla 2): imputamos con la mediana las continuas y eliminamos las observaciones con faltantes en las categóricas, salvo en el tamaño del establecimiento y el contrato temporal. En estas dos tratamos la no respuesta como una categoría más, porque eliminarlas nos hubiera costado 2.086 observaciones con 57,8 % de informales (contra 43,5 % en el resto), sacando de la muestra a un grupo muy informal. También descartamos eliminar toda observación con algún faltante, que nos hubiera dejado con 12.500 ocupados (63,9 %) y con un modelo que sólo sirve para quienes declaran ingresos. Con el criterio elegido conservamos 19.482 observaciones (99,6 %). La imputación la hacemos después de partir la base (inciso 4), con la mediana de la base de entrenamiento.

[4] Suponemos una duración de 7 años para el primario, 5 para el secundario, 3 para el terciario, 5 para el universitario y 2 para el posgrado. La educación especial queda como faltante, porque no tiene equivalencia en años.

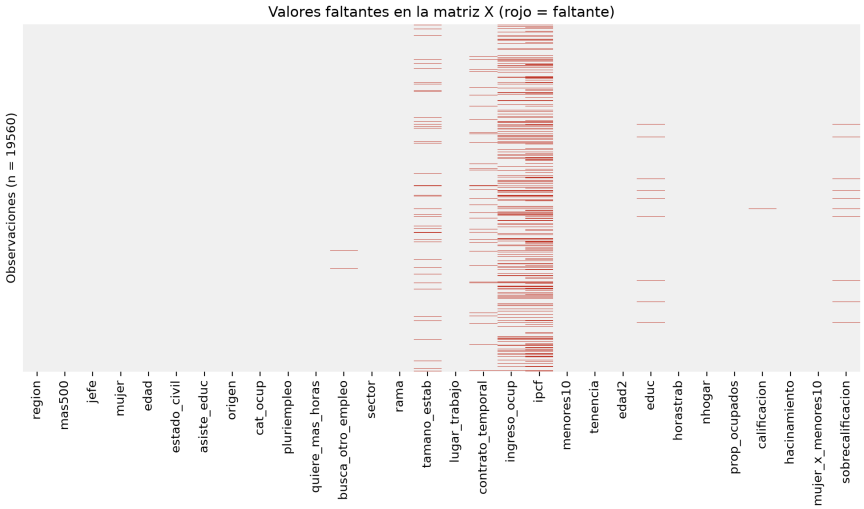


Figura 1: Valores faltantes en la matriz X antes del tratamiento (19.560 ocupados, 30 variables). En rojo, los faltantes. Por la resolución de la imagen, cada línea puede agrupar a varios ocupados contiguos.

Tabla 2: Tratamiento de los valores faltantes según el tipo de variable

Tipo	Variables	Tratamiento
Continuas	`edad`, `ingreso_ocup`, `ipcf`, `educ`, `horastrab`, `hacinamiento`	Mediana de entrenamiento (inciso 4). Ingresos: además, dummy de no declaración (`ingreso_nr`, `ipcf_nr`)
Categóricas con pocos faltantes	`busca_otro_empleo`, `quiere_mas_horas`, `calificacion`, `tenencia`, `origen`	Se elimina la fila (78 filas, 0,4 %)
Categóricas con muchos faltantes	`tamano_estab`, `contrato_temporal`	No respuesta como categoría (`ns_nr`) o dummy (`contrato_nsnr`)

Las variables categóricas pasan a *dummies*, dejando afuera una categoría de referencia por variable (indicada en la Tabla 1): como las *dummies* de una misma variable suman uno en cada fila, igual que la columna del intercepto, incluirlas todas generaría colinealidad perfecta. La matriz X final tiene 67 columnas.

La Tabla 3 compara las medias de una selección de variables entre formales e informales. Para las *dummies*, la media es la proporción del grupo con esa característica. En cada fila contrastamos la hipótesis nula de que ambas medias son iguales con un test t que no supone igual varianza entre los grupos (versión de Welch). Con casi 19.500 observaciones, prácticamente toda diferencia resulta significativa (59 de las 67 columnas de X), por lo que conviene mirar la magnitud más que el p-valor.

Las mayores diferencias aparecen en las características del puesto: el 74,1 % de los informales trabaja en establecimientos de hasta cinco personas (contra 26,1 % de los formales), sólo el 4,5 % trabaja en el sector estatal (contra 34,2 %) y el 37,9 % es cuentapropista (contra 14,4 %). Los informales tienen además 2,2 años menos de educación y un ingreso per cápita familiar de casi la mitad (562 frente a 1.047 miles de pesos). El sexo no muestra diferencias ($p = 0{,}086$), pero la interacción entre ser mujer y la cantidad de menores de 10 años sí, lo que sugiere que el sexo importa en combinación con la carga de cuidado. La sobrecalificación es más frecuente entre los formales, al revés de lo que esperábamos, quizás porque exige 15 o más años de educación y ese grupo es mayormente formal. Y no saber si el contrato tiene fecha de finalización aparece en el 9,7 % de los informales y en apenas el 0,9 % de los formales.

Inciso 4

Dividimos la base en una muestra de entrenamiento (70 %) y una de prueba (30 %) con `train_test_split` y semilla 444, lo que deja 13.637 y 5.845 ocupados, con 44,73 % y 45,46 % de informales, respectivamente. No

Tabla 3: Diferencia de medias entre ocupados formales ($n = 10.725$) e informales ($n = 8.757$). Selección de variables; test t de Welch.

Variable	Formales	Informales	Diferencia	p-valor
Edad (años)	43,490	39,412	−4,078	<0,001
Educación (años)	13,246	11,013	−2,233	<0,001
Horas trabajadas (semana)	36,535	33,374	−3,161	<0,001
Miembros del hogar	3,301	3,877	0,576	<0,001
Hacinamiento (personas por ambiente)	1,138	1,401	0,263	<0,001
Proporción de ocupados del hogar	0,648	0,627	−0,021	<0,001
Ingreso ocupación principal (miles de $)	1.311,5	552,0	−759,5	<0,001
Ingreso per cápita familiar (miles de $)	1.046,7	562,1	−484,5	<0,001
Mujer	0,448	0,460	0,012	0,086
Mujer × menores de 10	0,152	0,223	0,071	<0,001
Jefe/a de hogar	0,548	0,415	−0,133	<0,001
Cuenta propia	0,144	0,379	0,236	<0,001
Sector estatal	0,342	0,045	−0,297	<0,001
Establecimiento de hasta 5 personas	0,261	0,741	0,480	<0,001
Contrato con fecha de finalización	0,022	0,120	0,097	<0,001
Contrato: no sabe/no responde	0,009	0,097	0,088	<0,001
Quiere trabajar más horas	0,086	0,263	0,177	<0,001
Trabaja en domicilio del cliente	0,062	0,293	0,231	<0,001
Rama: construcción	0,042	0,155	0,113	<0,001
Rama: servicio doméstico	0,025	0,120	0,095	<0,001
Calificación: profesional	0,131	0,026	−0,106	<0,001
Calificación: no calificada	0,095	0,247	0,152	<0,001
Sobrecalificación	0,155	0,084	−0,071	<0,001
No declara ingreso de la ocupación	0,197	0,180	−0,018	0,002
Región Patagonia	0,148	0,070	−0,077	<0,001

estratificamos la partición: la consigna no lo pide y la proporción de informales de la muestra de prueba se aparta apenas 0,5 puntos porcentuales de la total, menos de un error estándar (0,65 puntos).

Imputamos los faltantes de las variables continuas con la mediana calculada sólo en la base de entrenamiento y la aplicamos a ambas bases, para que la base de prueba no intervenga en ninguna decisión del modelo. En nuestro caso, las medianas de entrenamiento coinciden con las de la base completa (por ejemplo, 800.000 pesos para el ingreso de la ocupación principal), porque los ingresos se declaran en montos redondos. Con la edad y la educación ya imputadas, recalculamos la edad al cuadrado (una observación) y la sobrecalificación de las 255 observaciones a las que les faltaba. Por último, agregamos la columna de unos para el intercepto del logit (LDA y KNN no la necesitan) y guardamos la base limpia en el repositorio (`base_limpia_TP1.csv`), con una columna que indica a qué muestra pertenece cada observación.

Parte II: Regresión logística y análisis discriminante

En esta parte estimamos $p = P(Y = 1 \mid X)$ con dos modelos sobre la base de entrenamiento: la regresión logística (incisos 5 y 6) y el análisis discriminante lineal (inciso 7). Ambos parten de la base limpia del inciso 4.

Inciso 5

La Tabla 4 reporta coeficientes, errores estándar y odds ratios para una selección de variables: las continuas, las construidas en el inciso 2 y las dummies que mostraron mayores diferencias en las medias entre formales e informales (Tabla 3). La tabla completa (68 coeficientes) está en el repositorio.

Interpretamos dos coeficientes: el de los años de educación, una variable continua, y el de querer trabajar más horas, una dummy que vale 1 para quienes quieren trabajar más horas y 0 para el resto. Cada coeficiente mide el efecto de su variable sobre el logaritmo de los odds, $\beta_k = \partial \ln\left(\frac{p}{1-p}\right) / \partial X_k$, y ese efecto es constante. Su signo indica la dirección: como p es una función creciente del log-odds, un β_k negativo reduce tanto los

Tabla 4: Regresión logística (variable dependiente: `informal`). Selección de coeficientes; entre paréntesis, la categoría de referencia. Ingresos en cientos de miles de pesos.

Variable	Coeficiente	EE	Odds ratio	p-valor
Ingreso ocupación principal (cientos de miles de $)	−0,1133	0,0069	0,893	<0,001
Ingreso per cápita familiar (cientos de miles de $)	0,0107	0,0059	1,011	0,070
Educación (años)	−0,1239	0,0116	0,883	<0,001
Edad (años)	−0,1147	0,0126	0,892	<0,001
Edad al cuadrado	0,0011	0,0001	1,001	<0,001
Mujer	0,0887	0,0674	1,093	0,188
Menores de 10 en el hogar	−0,0023	0,0579	0,998	0,968
Mujer × menores de 10	0,0904	0,0729	1,095	0,215
Hacinamiento (personas por ambiente)	0,1870	0,0467	1,206	<0,001
Proporción de ocupados del hogar	−0,1154	0,1255	0,891	0,358
Sobrecalificación	0,0615	0,0984	1,063	0,532
Contrato con fecha de finalización	2,3524	0,1185	10,510	<0,001
Contrato: no sabe/no responde	3,0327	0,1569	20,752	<0,001
Quiere trabajar más horas	0,3881	0,0900	1,474	<0,001
Cuenta propia (ref.: asalariado)	−0,2181	0,0900	0,804	0,015
Patrón (ref.: asalariado)	−0,5829	0,1570	0,558	<0,001
Sector estatal (ref.: privado)	−1,0468	0,1431	0,351	<0,001
Establecimiento hasta 5 personas (ref.: más de 40)	2,0935	0,1042	8,113	<0,001
Establecimiento 6 a 40 personas (ref.: más de 40)	0,7177	0,0910	2,050	<0,001
Domicilio del cliente (ref.: local u oficina)	1,1687	0,1142	3,218	<0,001
Rama: construcción (ref.: comercio)	0,5037	0,1375	1,655	<0,001
Rama: servicio doméstico (ref.: comercio)	−0,7702	0,1760	0,463	<0,001
Constante	2,7526	0,3623	15,683	<0,001
Observaciones (entrenamiento)				13.637
Pseudo R^2				0,466

odds como la probabilidad de ser informal, y uno positivo los aumenta. A su vez, e^{β_k} es el factor por el que se multiplican los odds cuando X_k aumenta en una unidad, manteniendo constantes las demás variables.[5] Así, cada año adicional de educación ($\hat{\beta} = -0{,}124$) multiplica los odds de ser informal por 0,883, es decir, los reduce un 11,7 %. Quienes quieren trabajar más horas ($\hat{\beta} = 0{,}388$) tienen odds de ser informal un 47 % mayores ($e^{\hat{\beta}} = 1{,}47$).

En cambio, la variación de la probabilidad estimada no es constante: derivando la función logística, $\partial p / \partial X_k = \beta_k \, p(1-p)$, que tiene el signo de β_k pero es máxima en $p = 1/2$ ($\beta_k/4$) y tiende a cero cuando p se acerca a 0 o a 1. Así, un año más de educación reduce la probabilidad de ser informal en 3,1 puntos porcentuales para un ocupado con $p = 0{,}5$, pero sólo en 1,1 puntos para uno con $p = 0{,}1$ o $p = 0{,}9$. Del mismo modo, querer trabajar más horas aumenta la probabilidad de ser informal en 9,6 puntos para un ocupado con $p = 0{,}5$, pero sólo en 4,1 y 3,0 puntos para uno con $p = 0{,}1$ y $p = 0{,}9$, respectivamente. [6]

Inciso 6

La Figura 2 muestra la probabilidad de ser informal estimada por el logit para cada ocupado de la base de entrenamiento, con todas sus características observadas, según sus años de educación, y su promedio para cada año. El gráfico confirma lo esperado: la probabilidad promedio cae a medida que aumenta la educación.

[5] Estos coeficientes son asociaciones condicionales, no efectos causales: indican cómo cambia la probabilidad estimada de ser informal.

[6] Para la educación, $\hat{\beta}\, p(1-p)$; por ejemplo, $-0{,}124 \times 0{,}5 \times 0{,}5 = -0{,}031$. Para la dummy, los odds de partida, $p/(1-p)$, se multiplican por $e^{\hat{\beta}} = 1{,}47$ y se vuelven a convertir en probabilidad: $p_1 = \frac{\text{odds}_1}{1+\text{odds}_1}$; por ejemplo, con $p = 0{,}5$, $1{,}47/2{,}47 = 0{,}596$, es decir, $0{,}596 - 0{,}5 = 9{,}6$ puntos más.

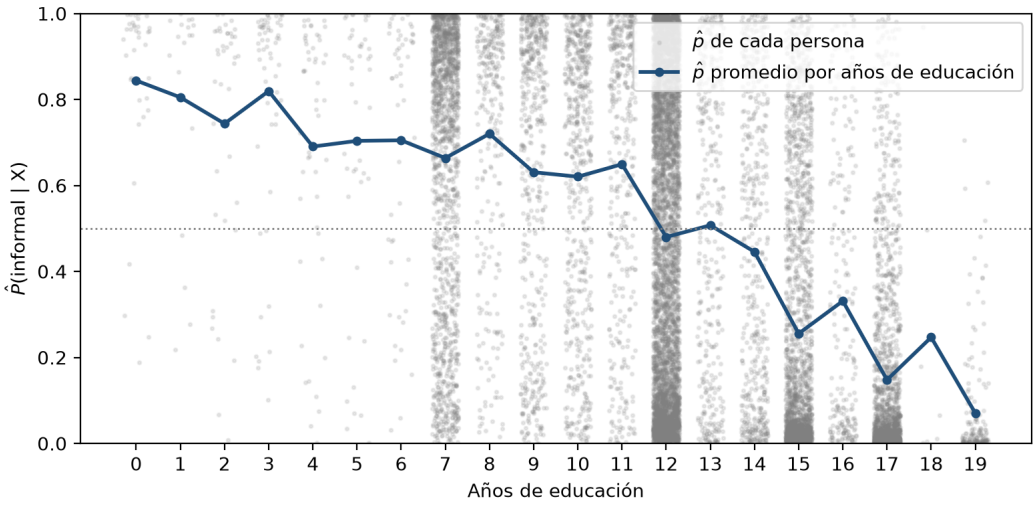


Figura 2: Probabilidad estimada de ser informal según los años de educación (base de entrenamiento). Cada punto es un ocupado, con un pequeño desplazamiento horizontal para que no se superpongan; la línea une el promedio de cada año.

Esa caída es mucho mayor que la que implica el coeficiente de la educación (inciso 5), y la diferencia ayuda a interpretarla. Puede haber un canal directo, por el que más educación facilita el acceso a empleos formales, pero quienes tienen más educación también difieren en otras características asociadas a la formalidad, como el tipo de puesto, el sector y el tamaño del establecimiento.

Inciso 7

A diferencia de la regresión logística, el análisis discriminante lineal (LDA) supone que, dentro de cada clase, X tiene distribución normal multivariada con una matriz de covarianzas común: $X \mid Y = k \sim \mathcal{N}(\mu_k, \Sigma)$, para $k \in \{0, 1\}$.

En la matriz X, 56 de sus 67 variables son binarias, y una variable que sólo toma los valores 0 y 1 no puede tener distribución normal. Es decir, el supuesto de normalidad no es razonable para nuestro caso. Sin embargo, que el supuesto no se cumpla no implica que LDA clasifique mal: si el costo de suponer normalidad es importante o no, lo determina su desempeño fuera de la muestra.

Parte III: Vecinos cercanos

Inciso 8

En esta sección, estimamos la probabilidad de ser informal con el método de vecinos cercanos o KNN. Lo hacemos para tres valores distintos de K, que es el hiperparámetro que determina cuántos vecinos se toman en cuenta a la hora de determinar el $\hat{p}$ de cada individuo. En concreto, estimamos para $K = 10$, 50 y 100, siempre usando el set de datos de entrenamiento estandarizando las distancias para cada variable. La exactitud es de 0,834, 0,815 y 0,812, respectivamente: va cayendo a medida que suben los vecinos. El resultado se vincula con el *tradeoff* sesgo-varianza. Con K chico la predicción depende de un puñado de vecinos y la clasificación es muy sensible a esos pocos que queden en torno a la observación y por lo tanto acusa poco sesgo, entendido como un error sistemático en un sentido determinado. La predicción, no obstante, va a cambiar mucho con la muestra (mucha varianza). Al subir K se promedian más vecinos y la predicción se vuelve más estable pero más rígida (aumenta el sesgo pero cae la varianza). Con K = 1 cada observación de entrenamiento es su propio vecino (overfit total en train, muchísima varianza en test). Con K = n todos reciben la misma predicción, que es directamente la clase mayoritaria en la población (en este caso, formal). Ahí el sesgo es máximo y la varianza nula.

Inciso 9

Ahora repetimos el proceso, pero separando la base de entrenamiento en 5 partes o folds. Luego de separar, iteramos cinco veces, siempre usando un fold como validación y los restantes como entrenamiento, y computamos la exactitud (aciertos sobre el total de observaciones del fold de validación) para cada K. Finalmente el K óptimo es aquel que maximiza el promedio en este indicador en las cinco iteraciones. Este método, que hace que las partes sean de a turnos entrenamiento y validación, se llama cross validation (en este caso, como estima KNN con CV, lo llamamos K-CV).

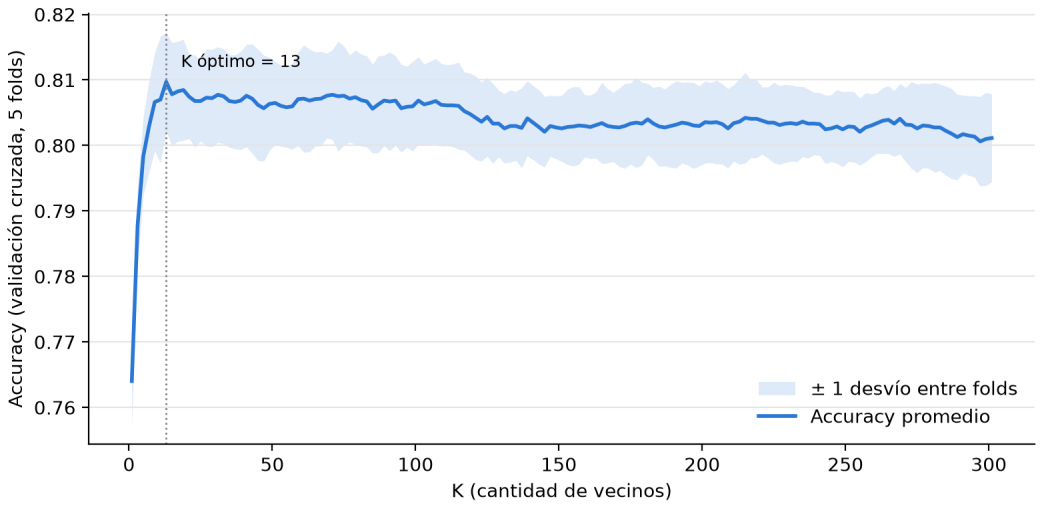


Figura 3: Exactitud de K-CV (5 folds de `X_train`) según el número de vecinos K. La banda indica ± 1 desvío entre los folds. La línea punteada marca el K óptimo.

La Figura 3 exhibe la exactitud para cada K. El óptimo se alcanza en $K = 13$ vecinos, con 0,81. Antes de eso, la exactitud sube rápidamente con cada vecino a medida que cae la varianza. Luego de ese punto, la varianza sigue cayendo pero a costa de introducir un sesgo sistemático que, como dijimos, lleva en el extremo a predecir siempre formal. Esto hace caer la exactitud lentamente, hasta 0,80 en el último punto que probamos ($K = 301$).

Parte IV: Desempeño de modelos y elección

Inciso 10

A continuación, evaluamos los tres modelos en la base de test utilizando los hiperparámetros que seleccionamos a lo largo del trabajo con la base de train.

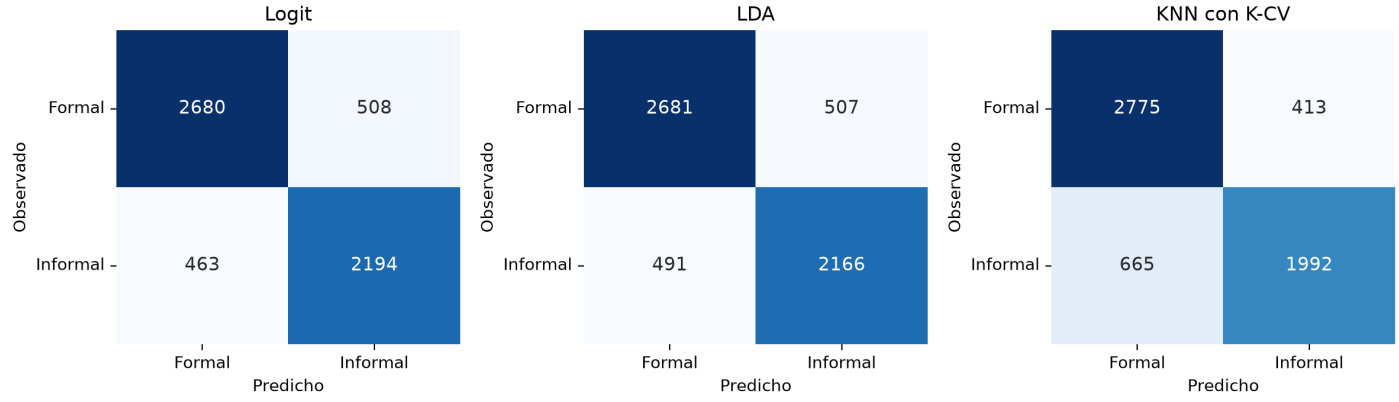


Figura 4: Matrices de confusión en la base de test ($n = 5.845$), con umbral $\hat{p} > 0{,}5$.

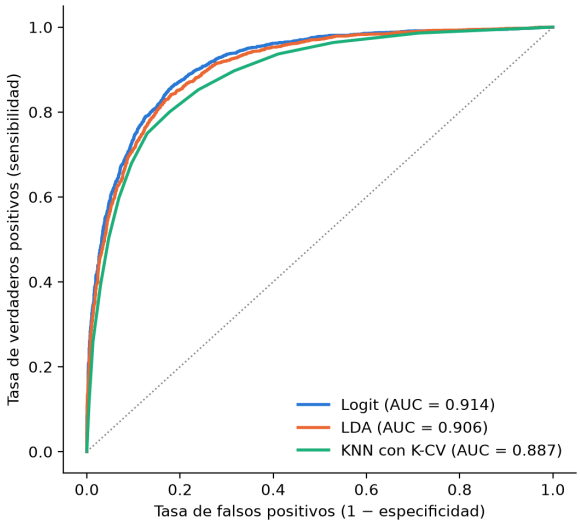


Figura 5: Curvas ROC en la base de test.

Métrica	Logit	LDA	KNN con K-CV
Verdaderos positivos	2.194	2.166	1.992
Falsos positivos	508	507	413
Falsos negativos	463	491	665
Verdaderos negativos	2.680	2.681	2.775
Exactitud	0,834	0,829	0,816
Sensibilidad	0,826	0,815	0,750
Especificidad	0,841	0,841	0,870
Valor predictivo positivo	0,812	0,810	0,828
AUC	0,914	0,906	0,887

Tabla 5: Desempeño en la base de test con umbral $\hat{p} > 0{,}5$.

La Figura 4 contiene las matrices de confusión para los tres métodos, siempre con un umbral de clasificación de 0,5. Estas resumen los verdaderos positivos y negativos en la diagonal principal, y los errores de Tipo I y II en las celdas fuera de ella. Luego, la Figura 5 presenta la curva ROC de cada modelo, mientras que la Tabla 5 resume algunas métricas relevantes que utilizaremos para contrastar los tres modelos.

Como primera conclusión, los tres modelos tienen un porcentaje elevado de exactitud, que es la cantidad de aciertos (verdaderos positivos y verdaderos negativos) sobre el total. KNN con K-CV, el de peor performance, alcanza 0,816, mientras que Logit alcanza 0,834. El buen desempeño de los modelos se ve también en las curvas ROC y en el área comprendida debajo de ellas, o AUC. Esta se puede interpretar como la capacidad de clasificación del modelo en general, ya que, a diferencia de las demás medidas, se calcula contemplando todos los posibles umbrales de $\hat{p}$. En este indicador, Logit también se destaca sobre los otros dos, tal como se aprecia en la curva superior en el gráfico y en las cifras de la tabla.

Las otras dos métricas, sensibilidad y especificidad, miran los aciertos dentro de cada clase por separado. La sensibilidad (verdaderos positivos sobre el total de informales) es de 0,826 en el Logit y 0,815 en LDA, pero cae a 0,750 en KNN, que falla en detectar a 665 informales frente a 463 del Logit. La especificidad (verdaderos negativos sobre el total de formales) es, en cambio, mayor en KNN (0,870 frente a 0,841). Esto no indica que KNN sea mejor, sino que es más conservador, ya que con el mismo umbral clasifica como informales a 2.405 personas, contra 2.702 del Logit. Por el mismo motivo, el valor predictivo positivo (verdaderos positivos sobre todos los que se clasificaron como informales) también favorece al KNN, que alcanza 82,8 % frente al 81,2 % del Logit y el 81,0 % de LDA. No obstante, como la curva ROC de KNN queda por debajo, para cualquier umbral el Logit ofrece una mejor combinación de errores.

Inciso 11

Si quisiéramos implementar un programa de formalización laboral utilizando los datos de la EPH, pero el presupuesto estuviera acotado, la clave sería minimizar los falsos positivos: lo peor que puede pasar es estar desperdiciando recursos en trabajadores formales clasificados erróneamente como informales. Una forma de plasmar ese criterio sería modificar el umbral de clasificación, aumentando el costo relativo del falso positivo respecto del falso negativo. Sea r el costo adicional del primero, y teniendo en cuenta que conviene clasificar a un trabajador como informal cuando $\hat{p} > (1 - \hat{p}) \cdot r$, la condición resulta $\hat{p} > r/(1 + r)$. Con $r = 1$ el umbral es $c = 0{,}5$ (como en el clasificador de Bayes), con $r = 2$ sube a 0,67 y con $r = 3$, a 0,75. Aumentar el costo hace más exigente a la clasificación, aumentando el umbral.

En cuanto al modelo, como discutimos previamente, el más apropiado es el Logit, ya que su curva ROC queda por encima de las otras dos en casi todo el recorrido, lo que lo hace el que tiene mejor combinación de errores para cada c posible. Por ejemplo, si fijamos el valor del programa, suponiendo que este alcanzara para el 20 % de los ocupados y se eligiera a quienes tienen mayor $\hat{p}$, el 94,4 % de los seleccionados por el logit serían efectivamente informales, frente al 93,5 % con LDA y el 91,7 % con KNN.

Tabla 6: Regresión logística en la base de test: seleccionados y errores según el umbral c (con r costo relativo implícito).

Umbral c	r implícito	Seleccionados	Falsos positivos	Falsos negativos	VPP	Sensibilidad
0,3	0,43	3.308	864	213	0,739	0,920
0,4	0,67	2.993	663	327	0,778	0,877
0,5	1,00	2.702	508	463	0,812	0,826
0,6	1,50	2.353	345	649	0,853	0,756
0,7	2,33	2.025	235	867	0,884	0,674
0,8	4,00	1.606	132	1.183	0,918	0,555
0,9	9,00	951	41	1.747	0,957	0,342

La Tabla 6 muestra cómo cambian los errores del Logit al subir el umbral. Con 0,5, el modelo selecciona 2.702 personas, de las cuales 508 son formales (o sea que alrededor del 19 % de los recursos se desperdiciaría), y deja afuera a 463 informales. Proponemos un umbral de 0,7 ($r = 2{,}33$). A ese nivel, los falsos positivos bajan a 235 y el valor predictivo positivo sube a 0,884, mientras que los informales que quedan afuera suben de 463 a 867 (la sensibilidad cae a 0,674).

En los hechos, el umbral lo terminaría fijando el propio presupuesto, ya que si este alcanza para N personas (o para un porcentaje, como en el ejemplo que dimos antes), se seleccionaría a las N personas con mayor $\hat{p}$. Vale destacar que si bien resolvimos el problema variando el umbral, tener falsos negativos conlleva sus propios problemas. Un umbral alto está dejando afuera a los informales más difíciles de detectar, ya que son los que más se parecen a los formales de acuerdo a las variables usadas. En otras aplicaciones, estos segmentos difíciles de clasificar pueden ser precisamente los más vulnerables o los que más interesa detectar, y los incentivos para diseñar el programa deberían ajustarse acordemente.

Declaración de uso de herramientas de inteligencia artificial

Utilizamos Claude [7] como asistente en las siguientes tareas en todas las instancias del trabajo:

- Escritura del código en Python, desde el procesamiento de las bases hasta la estimación y evaluación de los modelos.
- Análisis de estrategias metodológicas en las distintas etapas del trabajo.
- Diagnóstico y verificación de los resultados y de las estimaciones.
- Derivación algebraica del cambio en la probabilidad estimada, utilizada en la interpretación de coeficientes.
- Escritura del código en LaTex para insertar las tablas y figuras del informe.
- Revisión del notebook y de la versión final del entregable PDF, principalmente para buscar errores ortográficos o de redacción, y ocasionalmente para ajustar algunos detalles conceptuales.

[7] Opus 5.5 de Anthropic, nivel de esfuerzo Alto.